- 第二章　LMS自适应滤波

2.5　LMS算法变形

一 泄放因子（leakage factor）

$$\mathbf{H}(n+1)=\mathbf{H}(n)+\delta e(n+1)\mathbf{X}(n+1)$$

当输入信号消失时，递推式中系数被锁死在那儿，这时最好让其返回到**0**，以便下一次重新递归，从而有个稳定的行为。这可以通过加一个泄放因子来实现。

$$\mathbf{H}(n+1)=(1-\gamma)\mathbf{H}(n)+\delta e(n+1)\mathbf{X}(n+1)$$ 式中 $0<\gamma<1$

从而当 $\mathbf{X}(n+1)=0$ 时， $\mathbf{H}(n+1)\to 0$

将 $e(n+1)=y(n+1)-\mathbf{X}^T(n+1)\mathbf{H}(n)$ ，代入有

$$\mathbf{H}(n+1)=[(1-\gamma)\mathbf{I}_N-\delta\ \mathbf{X}(n+1)\mathbf{X}^T(n+1)]\ \mathbf{H}(n)\ +\ \delta\ y(n+1)\mathbf{X}(n+1)$$

收敛后，定义均值为：

$$\mathbf{H}_\infty=E[\mathbf{H}_{(\infty)}]=[(1-\gamma)\mathbf{I}_N-\delta\mathbf{R}]\ E[\mathbf{H}_{(\infty)}]+\delta\ \mathbf{r}_{yx}$$

$$\mathbf{H}_{\infty} = E[\mathbf{H}_{(\infty)}] = [(1-\gamma)\mathbf{I}_N - \delta\mathbf{R}]\ E[\mathbf{H}_{(\infty)}] + \delta\ \mathbf{r}_{yx}$$

$$E[\mathbf{H}_{(\infty)}] = [\gamma\mathbf{I}_N + \delta\mathbf{R}]^{-1}\delta\ \mathbf{r}_{yx}$$

$$\therefore \mathbf{H}_{\infty} = [\mathbf{R} + \frac{\gamma}{\delta}\mathbf{I}_N]^{-1}\ \mathbf{r}_{yx}$$

比较$\mathbf{H}_{opt} = \mathbf{R}^{-1}\ \mathbf{r}_{yx}$ ，可见泄放因子的引入，使滤波器系数即使是均值也不能收敛到 $\mathbf{H}_{opt}$

$$\mathbf{H}_{\infty} = [\mathbf{R} + \frac{\gamma}{\delta}\mathbf{I}_N]^{-1}\ \mathbf{R}\ \mathbf{H}_{opt}$$

这时相当于一个白噪声被叠加到输入信号 $x(n)$上产生同样的效果

$$[\mathbf{R} + \frac{\gamma}{\delta}\mathbf{I}_N] = [\mathbf{R}] + \begin{bmatrix} \frac{\gamma}{\delta} & \cdots & 0 \\ & \ddots & \\ 0 & & \frac{\gamma}{\delta} \end{bmatrix}$$

因为白噪声加到$x(n)$后求自相关矩阵时，除对角线元素变化，$\gamma(0)+\frac{\gamma}{\delta}$　其余由于噪声的独立性而为**0**

为了评定泄放因子的影响，我们重写系数矢量：

$$\mathbf{R}+\frac{\gamma}{\delta}\mathbf{I}_N=\mathbf{Q}\ diag(\lambda_i)\ \mathbf{Q}^T+\frac{\gamma}{\delta}\mathbf{Q}\ diag(1)\ \mathbf{Q}^T$$

$$=\mathbf{Q}\ diag(\lambda_i+\frac{\gamma}{\delta})\ \mathbf{Q}^T$$

$$[\mathbf{R}+\frac{\gamma}{\delta}\mathbf{I}_N]^{-1}=[\mathbf{Q}^T]^{-1}\ diag(\lambda_i+\frac{\gamma}{\delta})^{-1}\ \mathbf{Q}^{-1}$$

$$=\mathbf{Q}\ diag(\lambda_i+\frac{\gamma}{\delta})^{-1}\ \mathbf{Q}^T$$

$$\mathbf{H}_\infty=[\mathbf{R}+\frac{\gamma}{\delta}\mathbf{I}_N]^{-1}\ \mathbf{R}\ \mathbf{H}_{opt}$$

$$=\mathbf{Q}\ diag(\lambda_i+\frac{\gamma}{\delta})^{-1}\ \mathbf{Q}^T\ \mathbf{Q}\ diag(\lambda_i)\ \mathbf{Q}^T\ \mathbf{H}_{opt}=\mathbf{Q}\ diag(\frac{\lambda_i}{\lambda_i+\frac{\gamma}{\delta}})\ \mathbf{Q}^T\ \mathbf{H}_{opt}$$

$$\mathbf{H}_{\infty} = \mathbf{Q}\ diag\left(\frac{\lambda_i}{\lambda_i + \frac{\gamma}{\delta}}\right)\ \mathbf{Q}^T\ \mathbf{H}_{opt}$$

可见偏离取决于 $\lambda_{\min}$和 $\frac{\gamma}{\delta}$ 的相对大小

如果 $\frac{\gamma}{\delta} \ll \lambda_{\min}$ ，则 $\mathbf{H}_{\infty} = E[\mathbf{H}_{(\infty)}] \to \mathbf{H}_{opt}$

由于 $\mathbf{H}_{\infty} - \mathbf{H}_{opt} = [\mathbf{R} + \frac{\gamma}{\delta}]^{-1}\ \mathbf{R}\ \mathbf{H}_{opt} - \mathbf{H}_{opt} = \{[\mathbf{R} + \frac{\gamma}{\delta}]^{-1}\ \mathbf{R} - \mathbf{I}_N\}\mathbf{H}_{opt}$

所以残差 $J_{(\infty)} = J_{\min} + [\mathbf{H}_{\infty} - \mathbf{H}_{opt}]^T\ \mathbf{R}\ [\mathbf{H}_{\infty} - \mathbf{H}_{opt}]$

泄放因子尤其对于处理非平稳信号有用，适当选择泄放因子可减小输出误差功率。

（语音信号中，试验表明，$\delta = 2^{-6}$，$\gamma = 2^{-8}$是一种好的选择）

$$0 < \delta < \frac{2}{N\sigma_x^2}$$

$$\tau_e \approx \frac{1}{\delta\sigma_x^2}$$

二、符号算法（sign Algorithm）：

LMS算法中，系数自适应遵循

$$\mathbf{H}(n+1) = \mathbf{H}(n) + \delta e(n+1)\mathbf{X}(n+1)$$

导致滤波器中（N＋1）次乘法（相对于FIR，额外）. 而当信号是非平稳时（如 σ_x^2 在变化），尚需估计 σ_x^2 ，用 $\frac{1}{\tau_e\sigma_x^2}$ 代替 δ（如希望时间常数保持稳定：$\frac{1}{\delta\sigma_x^2} = \tau_e$）。

实用中有一种简化算法 —— 符号算法。

$$\mathbf{H}(n+1) = \mathbf{H}(n) + \Delta \ sign[e(n+1)] \ sign[\mathbf{X}(n+1)]$$

式中符号函数 $sign(x) = \frac{x}{|x|}$

若近似将 $|x|$ **，看着信号的有效值** σ_x **。这里** $\sigma_x = \sqrt{E[x^2(n)]}$

$$\mathbf{H}(n+1)=\mathbf{H}(n)+\ \Delta\ \ sign[e(n+1)]\ \ sign[\mathbf{X}(n+1)]$$

这时上式仍可近似看作是**LMS**算法:

$$\mathbf{H}(n+1)=\mathbf{H}(n)+\ \Delta\frac{1}{\sigma_e\sigma_x}\ e(n+1)\mathbf{X}(n+1)$$

但是 $\delta\approx\dfrac{\Delta}{\sigma_x\sigma_e}$

这里σ_x,σ_e是输入信号和输出误差的有效值。

在学习状态（指开始递推，达稳态之前），由于初始值H(0)=0，可假设$\sigma_e\approx\sigma_y$，则符号算法初始时间常数可近似估计为

$$\delta\approx\frac{\Delta}{\sigma_x\sigma_e}$$

$$\tau\approx\frac{1}{\delta\sigma_x^2}\quad\Rightarrow\quad\therefore\tau_s\approx\frac{1}{\Delta}\frac{\sigma_y}{\sigma_x}$$

收敛后，可合理假设 $\sigma_e^2 = J_{\min}$

则可估计符号算法均方收敛误差：

$$J(\infty) \approx J_{\min}(1+\frac{\delta}{2}N\sigma_x^2)$$

$$\approx J_{\min}(1+\frac{\Delta N\sigma_x}{2\sqrt{J_{\min}}})$$

$$\sigma_e^2 = J_{\min}$$

$$\delta \approx \frac{\Delta}{\sigma_x\sigma_e} \Rightarrow \delta \approx \frac{\Delta}{\sigma_x\sqrt{J_{\min}}}$$

超量残差：

$$J_{ex}(\infty) = \sqrt{J_{\min}}\,\frac{\Delta N\sigma_x}{2}$$

根据稳定性条件，$0 < \delta < \frac{2}{N\sigma_x^2}$ ，　故 Δ取值条件：

$$0 < \Delta < \frac{2}{N}\,\frac{\sqrt{J_{\min}}}{\sigma_x}$$

同样为了适应处理非平稳的情况，亦可以加入泄放因子在符号算法中。

$$\mathbf{H}(n+1)=(1-\gamma)\mathbf{H}(n)+\Delta\ \ sign[e(n+1)]\ \ sign[\mathbf{X}(n+1)]$$

在这些条件下：

$$\left|\gamma\mathbf{H}(n)\right|=\left|\Delta\ \ sign[e(n+1)]\ \ sign[\mathbf{X}(n+1)]+\mathbf{H}(n)-\mathbf{H}(n+1)\right|$$

$$\le\left|\Delta\right|+\left|\mathbf{H}(n)-\mathbf{H}(n+1)\right| \Rightarrow |\mathbf{H}(n)|\le|\frac{\Delta}{\gamma}|+|\varepsilon|$$

即系数被限制在 $|h_i(n)|\le\frac{\Delta}{\gamma}$ $0\le i\le N-1$

一般讲符号算法比标准的梯度算法（LMS）收敛慢，超量误差大，但是却十分简单（保留了和固定系数滤波器相同的乘法次数），由于step-size具有归一化性质，robust较好。它又能处理非平稳型号，故它亦是一种较广泛使用的自适应算法。

$$\delta\approx\frac{\Delta}{\sigma_x\sigma_e}$$

2.6 非平稳环境下的LMS算法

一 梯度失调误差和跟踪误差

对非平稳信号，自适应滤波器期待尽可能地跟踪上信号特性的变化，但是由于时间常数的关系，总存在延迟。因此超量误差有失调和跟踪两个误差组成。自适应的有效性取决于信号特性。显然最好情况下，信号是慢变化的,保证自适应过程能够跟踪上信号的变化。引起非平稳性的情况有：

- 参考信号是非平稳的
- AF输入信号是非平稳的
- 参考信号和输入信号都是非平稳的

由于 $H_{opt}(n)$ 是时变的，未知的，故系数误差矢量:

$$C(n)=H(n)-H_{opt}(n)=\{H(n)-E[H(n)]\}+\{E[H(n)]-H_{opt}(n)\}$$

其中 $C_1(n) = H(n) - E[H(n)]$

是梯度失调引起，相当于权系数矢量噪声

$$C_2(n) = E[H(n)] - H_{opt}(n)$$

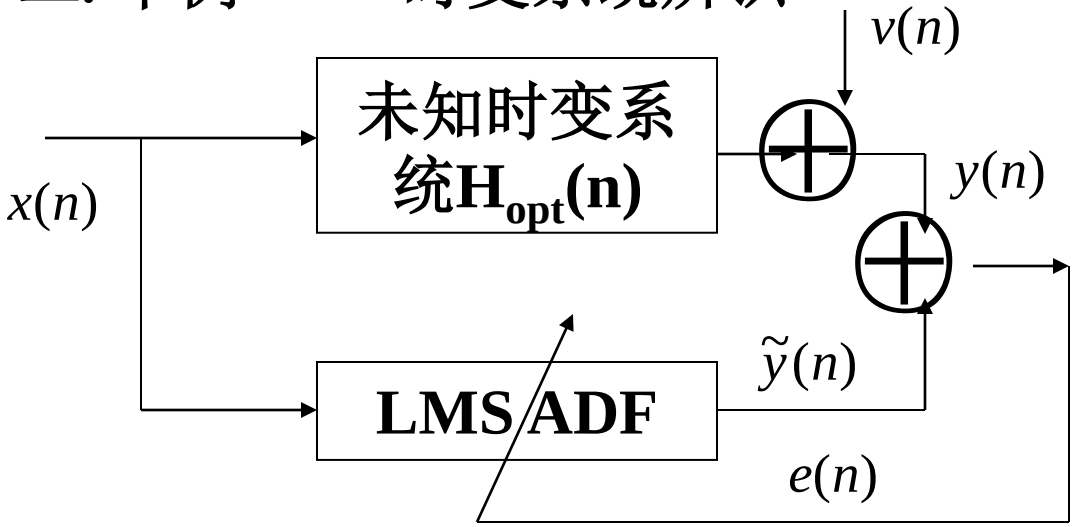
是跟踪误差，由于自适应过程的滞后引起，称为权系数矢量滞后误差.

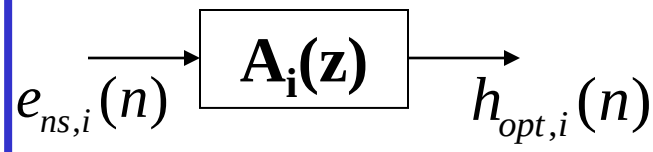
若LMS算法被应用到平稳环境时, $H_{opt}(n)$ 是常数H_{opt}

$$E[H(n)] = H_{opt} \qquad C_2(n) = 0$$

即无跟踪误差.

二. 举例 —— 时变系统辨识





$$A_i(z)=\frac{1}{1-\gamma z^{-1}}$$

$\gamma<1$但接近于1

表示只有慢变化成分通过

设：

1）未知系统的 $\mathbf{H}_{opt}(n)$ 是由一组零均值i.i.d（独立同分布），方差为δ_{ns}^2 的随机噪声 $e_{ns,i}(n)$，激励一个一阶低通滤波器模型所产生，有：

$$\mathbf{H}_{opt}(n+1)=\mathbf{H}_{opt}(n)+\mathbf{e}_{ns}(n+1)$$

这里

$$\mathbf{e}_{ns}(n+1)=\begin{bmatrix} e_{ns,0}(n+1) \\ e_{ns,1}(n+1) \\ \cdots \\ e_{ns,N-1}(n+1) \end{bmatrix}$$

2)输入*x*(n)是平稳的，具有零均值，自相关矩阵R

3)未知系统输出受白噪声 $\{v_n\}$ 污染（设为0均值，方差 σ_v^2 ），由于该噪声的存在和未知系统的时变性，使AF和未知系统之间匹配存在差别。

$$\boldsymbol{\alpha}(n+1)=\mathbf{Q}^T[\mathbf{H}(n+1)-\mathbf{H}_{opt}]=\mathbf{Q}^T[\mathbf{H}(n)+\delta e(n+1)\mathbf{X}(n+1)-\mathbf{H}_{opt}]$$
$$=\boldsymbol{\alpha}(n)+\delta\mathbf{Q}^T e(n+1)\mathbf{X}(n+1)$$

由于$\mathbf{H}_{opt}(n)$是自适应滤波器跟踪的目标，当

$$\mathbf{H}(n)=\mathbf{H}_{opt}(n)$$

时，则 $J_{\min}=\sigma_v^2$ 而 $y(n)$ 是未知系统的输出，它是时变的。

$$\mathbf{H}_{opt}(n+1)=\mathbf{H}_{opt}(n)+\mathbf{e}_{ns}(n+1)$$

从
$$[\boldsymbol{\alpha}(n+1)]=\mathbf{Q}^T[\mathbf{H}(n+1)-\mathbf{H}_{opt}(n+1)]$$
$$=\mathbf{Q}^T[\mathbf{H}(n)+\delta e(n+1)\mathbf{X}(n+1)-\mathbf{H}_{opt}(n+1)]$$
$$=[\boldsymbol{\alpha}(n)]+\delta\mathbf{Q}^T\mathbf{X}(n+1)e(n+1)-\mathbf{Q}^T\mathbf{e}_{ns}(n+1)$$

和原来相比多了一项$\mathbf{Q}^T\mathbf{e}_{ns}(n+1)$ ，且 $\mathbf{e}_{ns}(n+1)$ 和其他变量都不相关，因此 $E\{[\boldsymbol{\alpha}(n+1)][[\boldsymbol{\alpha}(n+1)]^T\}$ 中多了一项

$$\mathbf{Q}^T E\{[\mathbf{e}_{ns}(n+1)][\mathbf{e}_{ns}(n+1)]^T\}\mathbf{Q}=\sigma_{ns}^2\mathbf{I}_N$$

$$J(n) = J_{\min} + \sum_{i=0}^{N-1} \lambda_i E[\alpha_i^2(n)]$$

$$E\{[\boldsymbol{\alpha}(n+1)][\boldsymbol{\alpha}(n+1)]^T\} = [\mathbf{I}_N - 2\delta diag(\lambda_i)]E\{[\boldsymbol{\alpha}(n)][\boldsymbol{\alpha}(n)]^T\} +$$

$$\delta^2 E[e^2(n+1)]diag(\lambda_i) + \sigma_{ns}^2 \mathbf{I}_N$$

$$\boldsymbol{\beta}(n+1) = E[\boldsymbol{\alpha}^2(n+1)] = \mathbf{B}\boldsymbol{\beta}(n) + \delta^2 J_{\min}\boldsymbol{\Lambda} + \sigma_{ns}^2 \mathbf{I}_N$$

$$b_{ij} = \begin{cases} (1-\delta\lambda_i)^2 & i = j \\ \delta^2 \lambda_i \lambda_j & i \neq j \end{cases}$$

$$\beta_i(n+1) = [1-\delta\lambda_i]^2 \beta_i(n) + \delta^2 \lambda_i \sum_{\substack{j=0 \\ j\neq i}}^{N-1} \lambda_j \beta_j(n) + \delta^2 J_{\min}\lambda_i + \sigma_{ns}^2$$

$n \to \infty$ 时，忽略 δ^2 项，则近似有：$\beta_i(\infty) = \frac{\delta}{2} J_{\min} + \frac{\sigma_{ns}^2}{2\delta}\lambda_i^{-1}$

$$\therefore J(\infty) = J_{\min} + \sum_{i=0}^{N-1} \lambda_i \beta_i(\infty)$$

$$= \underbrace{J_{\min}(1 + \frac{\delta}{2} N\sigma_x^2)}_{\text{失调误差}} + \underbrace{\frac{\sigma_{ns}^2}{2\delta} N}_{\text{跟踪误差}}$$

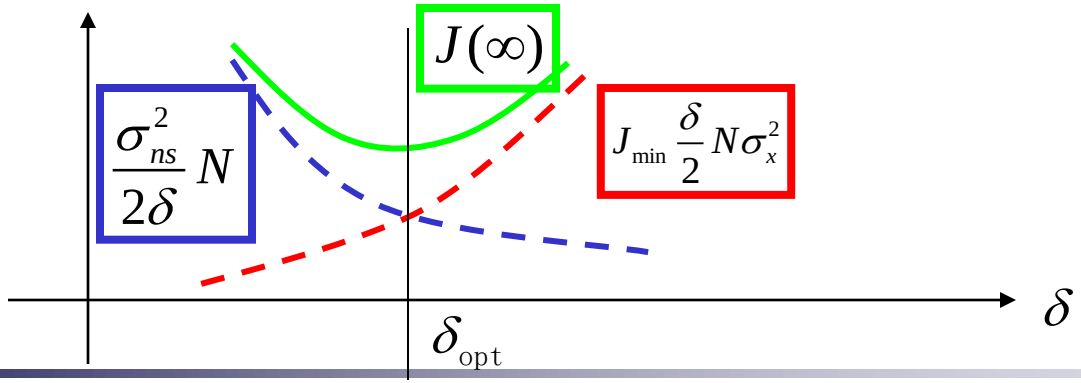
上式简洁地表示出参考信号非平稳时，失调误差和跟踪误差对总误差的贡献。显然这二项误差都与 δ 大小有关，但互相制约。

因为一项与 δ 成正比，一项与 δ 成反比，δ 的一种选择是使误差平衡分布。即

$$\frac{\delta}{2}N\sigma_x^2 J_{\min} = \frac{\sigma_{ns}^2}{2\delta}N \qquad \therefore \delta_{opt} = \frac{\sigma_{ns}}{\sigma_x}\frac{1}{\sqrt{J_{\min}}}$$

则 $$J(\infty) = J_{\min}(1+\frac{N\sigma_{ns}\sigma_x}{2\sqrt{J_{\min}}}) + \frac{N\sigma_{ns}\sigma_x}{2}\sqrt{J_{\min}}$$

以上模型是相对粗糙的，但是它对更复杂情况下的滤波器的行为给出了很多启示。



$$\tau_e \approx \frac{1}{\delta\sigma_x^2}$$

三. 归一化LMS方法（NLMS）

如果输入信号的一些重要的参数可以实时估计的话，自适应滤波器的性能可以大大改善。

对LMS算法来讲，最重要的参数是输入信号的功率，因为它影响 δ 的大小。如果输入信号的功率可以实时估计的话，则可以采用归一化的LMS算法

$$\mathbf{H}(n+1) = \mathbf{H}(n) + \frac{\Delta}{\sigma_x^2} e(n+1)\mathbf{X}(n+1)$$

$\sigma_x^2(n)$

此时相当于**step size**为 $\delta = \frac{\Delta}{\sigma_x^2}$ ， 是在浮动的。

优点是:

- 原来递推式中 δ 是固定值，要考虑到 σ_x^2 的变化，即 σ_x^2 最大时 δ 要满足的收敛条件（ $\delta < \frac{2}{N\sigma_x^2}$ ），因此，

δ的值不敢取得太大，而归一化后，等效 δ 在浮动，故 Δ 可取较大值；实际中多数情况下，σ_x^2 小，等效 δ 值也比较大，故收敛快。

•残差：
$$J(\infty) \approx J_{\min}(1+\frac{\delta N \sigma_x^2}{2})$$
$$= J_{\min}(1+\frac{\Delta N}{2})$$

时间常数：$\tau_e \approx \frac{1}{\delta\sigma_x^2} = \frac{1}{\Delta}$

这里 $\delta\sigma_x^2 = \Delta$ 是常数，故归一化的结果，使残差 $J(\infty)$ 和时间常数 τ_e 近似不随信号的性质变化。

σ_x^2的估计：

$$P_x(n) = (1-\alpha)P_x(n-1) + \alpha x^2(n)$$